Integración de Servicios Cloud GCP

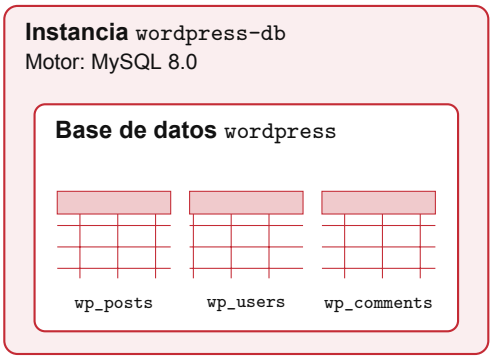
Big Data y BigQuery: preguntas a millones de filas con SQL

Semana 12 - Sesión 24

Rel Guzman



Revisión: Cloud SQL por dentro



Instancia: el servidor MySQL que Google crea y mantiene. Al crearla eliges el motor.

Base de datos: un espacio con nombre dentro de la instancia. Una instancia puede tener varias.

Tabla: donde quedan las filas. WordPress creó las suyas al instalarse.

Pregunta rápida

Si mañana necesitas otra base de datos, ¿tienes que crear otra instancia?

Caso de estudio: Pedidos Express crece

Enunciado

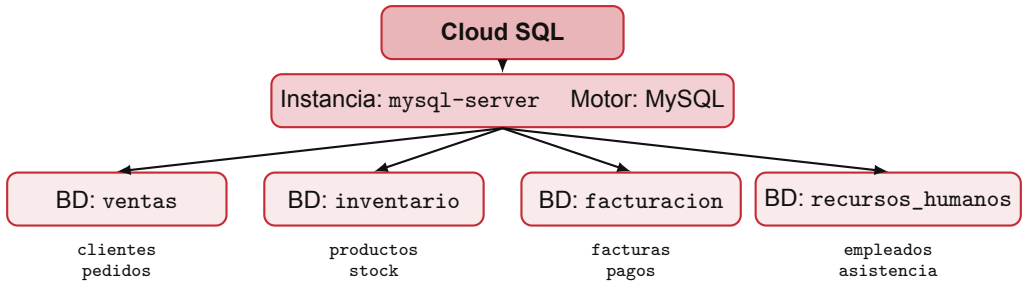
Pedidos Express ya tiene cuatro áreas: **ventas**, **inventario**, **facturación** y **recursos humanos**. Cada una necesita guardar sus datos en Cloud SQL. Diseña cómo quedaría.

- Pedido P-1001 de Ana
- Stock de audífonos: 35
- Factura F-101: S/ 250
- Sueldo de un repartidor
- Producto: Mouse, S/ 59
- Pago de la factura F-101
- Asistencia de un empleado

Responde

1. ¿Cuántas instancias creas? 2. ¿Cuántas bases de datos y con qué nombres? 3. ¿En qué base va cada dato de arriba?

Caso de estudio: una solución



¿Por qué así?

Una instancia: un solo servidor que pagar y mantener; alcanza para empezar.
Una base por área: cada área encuentra rápido sus tablas y los sueldos no se mezclan con los pedidos.

En la consola

Cloud SQL → `mysql-server` → **Bases de datos** → **Crear base de datos**. Se repite una vez por área.

Revisión: la pregunta de hoy



Registrar

La app guarda un pedido a la vez. Cada operación toca **una fila**. Cloud SQL está hecho para eso.

Analizar

La pregunta del gerente debe recorrer **todas las filas** del historial. Si corre en la misma base, la app se pone lenta mientras tanto.

La idea de hoy

Para preguntas sobre millones de filas se usa una herramienta pensada para analizar: **BigQuery**.

Logro de la sesión

Al finalizar, podrás explicar qué es **Big Data** y por qué **BigQuery** responde rápido sobre millones de filas, cargar una tabla en BigQuery y responder preguntas de negocio con consultas **SQL** que filtran, agrupan y suman.

Saberes previos

- ¿Cuántas filas crees que caben en una hoja de Excel?
- Pedidos Express recibe unos 1 100 pedidos al día. ¿Cuántos pedidos tendrá después de 3 años? ¿Podrías abrirlos en Excel?
- Tienes la lista de todos los pedidos con su categoría y su monto. ¿Cómo sacarías cuánto se vendió en cada categoría?

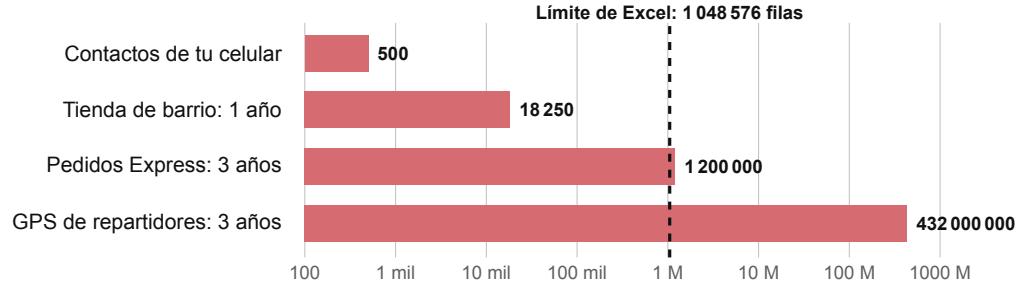
Utilidad de esta sesión

Las empresas acumulan años de ventas, cobros y registros de uso. Si sabes hacerles preguntas con **SQL** (qué se vende más, en qué mes, en qué distrito, en qué se gasta), esos datos se convierten en decisiones. Con **BigQuery** lo haces sin instalar ni administrar servidores.

Parte 1: ¿qué es Big Data?

Cuando los datos ya no caben en las herramientas de siempre

¿Cuándo los datos son “grandes”?



Cada línea vertical vale 10 veces la anterior (M = millones). GPS: 1 posición cada 5 s durante 30 min de reparto = 360 por pedido.

Big Data

Datos tan grandes, que llegan tan rápido o tan variados que una hoja de cálculo o una sola computadora ya no los procesa a tiempo.

Las tres V de Big Data

Volumen

¿Cuántos datos hay?

1.2 millones de pedidos
432 millones de posiciones GPS

Velocidad

¿Qué tan rápido llegan?

Cada repartidor envía su ubicación cada 5 segundos, todo el día

Variedad

¿En qué forma llegan?

Tablas de pedidos, fotos de productos, reseñas escritas y coordenadas GPS

Basta con una

Si solo una de las tres V crece mucho, la hoja de cálculo o la base de siempre empiezan a quedarse cortas.

Registrar y analizar no son lo mismo

Registrar: “Guarda el pedido P-1001 de Ana”

pedido	fecha	cliente	categoria	monto
P-0998	2025-12-31	Luis	Moda	98
P-0999	2025-12-31	Rosa	Supermercado	24
P-1000	2025-12-31	Carlos	Electrónica	59
P-1001	2025-12-31	Ana	Hogar	149

La app agrega **una fila nueva**, con todas sus columnas, y termina.

Analizar: “¿Cuánto se vendió por categoría?”

pedido	fecha	cliente	categoria	monto
P-0001	2023-01-01	Marta	Moda	98
P-0002	2023-01-01	Jorge	Electrónica	295
⋮	⋮	⋮	⋮	⋮
P-1001	2025-12-31	Ana	Hogar	149

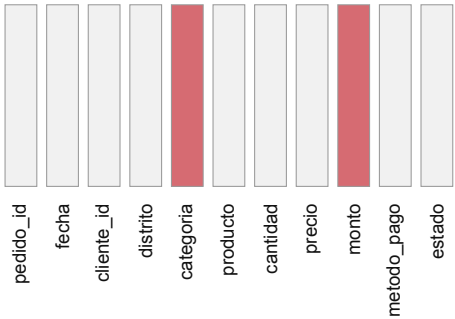
Lee **todas las filas** de los 3 años, pero solo **2 columnas**: `categoria` y `monto`. Suma los montos de cada categoría.

	Registrar (Cloud SQL)	**Analizar** (BigQuery)
Filas que usa	1, la del pedido nuevo	Todas: 1.2 millones
Columnas que usa	Todas las de esa fila	Solo las que pide la pregunta
Cuánto tarda	Milisegundos	Segundos
Cuántas veces al día	Miles: una por pedido	Pocas: una por reporte

¿Cómo responde rápido BigQuery? Dos ideas

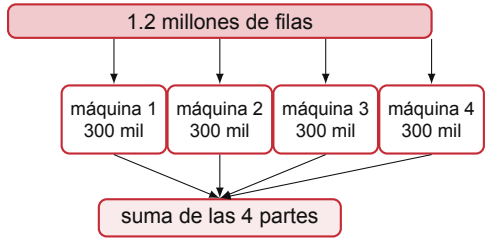
1. Guarda cada columna por separado

Si la consulta usa `categoria` y `monto`, lee **solo esas dos** de las 11 columnas.



2. Reparte el trabajo entre muchas máquinas

Cada máquina suma su parte al mismo tiempo; al final se juntan los resultados.



Google usa cientos o miles de máquinas. Tú solo escribes la consulta.

Parte 2: BigQuery

Guardar tablas enormes y hacerles preguntas con SQL

¿Qué es BigQuery?

Definición

Servicio de Google Cloud para guardar tablas muy grandes y responder preguntas sobre ellas con SQL. **No creas servidores:** cargas los datos y escribes la consulta.

	Cloud SQL	BigQuery
Para qué	Registrar lo que pasa en la app	Analizar el historial
Qué creas	Una instancia: eliges motor y máquina	Un dataset y sus tablas; ningún servidor
Cuántas filas	Miles o millones	Millones o miles de millones
Consulta típica	Trae el pedido P-1001	Suma las ventas de 3 años por categoría
Cómo cobra	Por las horas que la instancia está encendida	Por los datos guardados y los que lee cada consulta

Las dos hablan SQL

Lo que aprendas a consultar en una sirve en la otra.

Cómo se organiza BigQuery



En la consulta se escribe `dataset.tabla`

```
SELECT * FROM `billing_dataset.sampleinfotable` LIMIT 10
```

SQL para analizar (1): elegir y filtrar

Tabla `pedidos`

pedido	categoria	monto
P-1	Moda	98
P-2	Electrónica	295
P-3	Supermercado	12
P-4	Supermercado	0
P-5	Supermercado	56
P-6	Electrónica	59

```
SELECT pedido, monto
FROM pedidos
WHERE monto > 60
ORDER BY monto DESC
```



pedido	monto
P-2	295
P-1	98

`SELECT`	qué columnas
`FROM`	de qué tabla
`WHERE`	qué filas
`ORDER BY`	en qué orden
`LIMIT`	cuántas filas

Se lee así

“Muéstrame el pedido y el monto de la tabla `pedidos`, solo los que pasan de 60, del más caro al más barato”.

SQL para analizar (2): agrupar, contar y sumar

Tabla `pedidos`

pedido	categoria	monto
P-1	Moda	98
P-2	Electrónica	295
P-3	Supermercado	12
P-4	Supermercado	0
P-5	Supermercado	56
P-6	Electrónica	59

```sql
SELECT categoria,
  COUNT(*) AS pedidos,
  SUM(monto) AS total
FROM pedidos
GROUP BY categoria
ORDER BY total DESC
```

Resultado

categoria	pedidos	total
Electrónica	2	354
Moda	1	98
Supermercado	3	68

Qué hace cada parte

`GROUP BY` junta las filas con la misma categoría (mismo color). `COUNT(*)` cuenta las filas de cada grupo y `SUM(monto)` suma sus montos.

Mira el resultado

Supermercado tiene **más pedidos**, pero Electrónica **vende más dinero**. Contar y sumar responden preguntas distintas.

Práctica 1

Realiza el laboratorio

Examina los datos de facturación con BigQuery

`skills.google/catalog_lab/1784`

Al terminar

Sabes qué servicio de Google Cloud generó el mayor costo en los datos de ejemplo.

Práctica 2: BigQuery sin BigQuery

Qué harás

Consultas como las del lab con **Python** y **DuckDB**: un motor SQL que corre dentro de Python y, como BigQuery, lee por columnas. No necesitas cuenta de Google Cloud.

De dónde salen los datos

No se descargan: la primera celda del notebook ejecuta `generar_ventas.py`, que crea `ventas.csv` con **1.2 millones** de pedidos de Pedidos Express (2023–2025). Todos obtienen los mismos datos.

```
import duckdb

duckdb.sql("""
  SELECT categoria,
    ROUND(SUM(monto), 2) AS total_soles
  FROM ventas
  GROUP BY categoria
  ORDER BY total_soles DESC
""")
```

Cómo empezar

1. En Colab: **Archivo** → **Abrir cuaderno** → **GitHub**.
2. Pega el repositorio del curso:
   `github.com/rgap/rgap-Integracion-de-Servicios-Cloud-Gcp-Agosto2026`
3. Elige `Sesion24/practica/practica_bigquery_python.ipynb`, ejecuta las celdas en orden y resuelve los 5 retos del final.

Cierre: preguntas para comprobar

Responde con tus palabras

1. En el caso de estudio, ¿por qué basta una instancia con cuatro bases de datos?
2. Nombra las tres V de Big Data con un ejemplo de Pedidos Express.
3. ¿Por qué BigQuery lee menos datos si la consulta usa solo dos columnas?
4. En una consulta que suma los montos por categoría, ¿qué hace `GROUP BY`?
5. En la práctica, ¿la categoría con más pedidos fue la que más dinero vendió? ¿Por qué?

Idea final

Cloud SQL registra el día a día; BigQuery responde preguntas sobre todo el historial. Las dos se consultan con SQL.

Referencias

- Laboratorio: *Examina los datos de facturación con BigQuery* (*Examining Billing Data with BigQuery*), curso *Essential Google Cloud Infrastructure: Core Services*: `skills.google/catalog_lab/1784`.
- Práctica de la sesión: `github.com/rgap/rgap-Integracion-de-Servicios-Cloud-Gcp-Agosto2026`, carpeta `Sesion24/practica/` (`practica_bigquery_python.ipynb` y `generar_ventas.py`).
- DuckDB: `duckdb.org`.
- Material previo del curso: Sesión 23, bases de datos en Google Cloud y Cloud SQL.
- Google Cloud: BigQuery, Cloud SQL y Cloud Storage.
- Las respuestas de las preguntas están en `../respuestas.md`.