Integración de Servicios Cloud GCP

Balanceo de carga, CDN y contenedores

Semana 13 - Sesión 26

Rel Guzman



Revisión: lo que vimos en la Sesión 25

Supervisar

Mirar métricas y registros, y recibir una alerta cuando algo sale de lo normal.

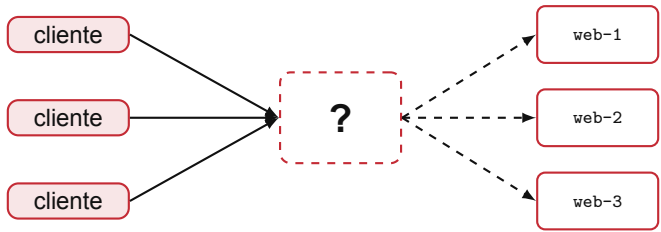
Alta disponibilidad

Tener varias copias en zonas distintas, para que una falla no apague el servicio.

Responde

1. ¿Qué servicio de Google Cloud te envía un correo si la CPU de `web-1` pasa del 80 %?
2. ¿Qué es un punto único de falla?
3. ¿Por qué conviene tener VMs en zonas distintas?

Revisión: la pregunta de hoy



1. Balanceo de carga	2. CDN	3. Contenedores
Tenemos 3 servidores. ¿Cómo se reparten los clientes?	¿Cómo hacer que las fotos carguen rápido en Lima?	¿Cómo poner el mismo programa en los 3 servidores sin instalar todo a mano?

Logro de la sesión

Al finalizar, podrás explicar con tus palabras qué es un **balanceador de carga**, qué es una **CDN** y en qué se diferencian una **imagen** y un **contenedor**.

Saberes previos

- Si 100 personas abren a la vez una página que corre en un solo servidor, ¿qué crees que pasa?
- Desde Lima abres la página de una tienda de EE. UU. ¿Crees que carga igual de rápido que una tienda con servidores en Lima?
- Un compañero te pasa su proyecto y en tu computadora no funciona. ¿Qué podría faltar?

Utilidad de esta sesión

Cuando una aplicación tiene muchos clientes, se ponen **varias copias** de ella. Hoy verás cómo se reparten los clientes entre esas copias, cómo se entregan las fotos desde cerca y cómo lograr que todas las copias sean iguales.

Parte 1: balanceo de carga

Repartir a los clientes entre varios servidores

El problema: un solo servidor

El caso

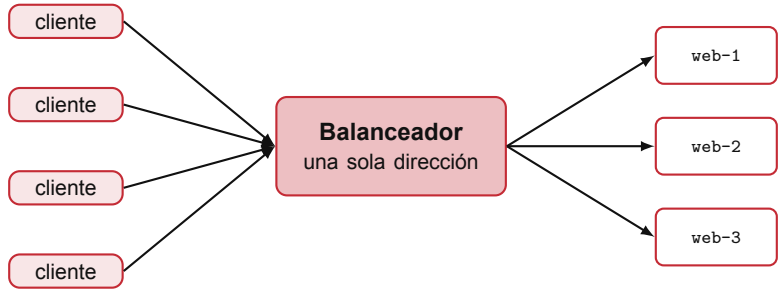
Seis clientes piden un reporte de ventas al mismo tiempo. Cada reporte tarda **5 segundos** y el servidor hace **uno a la vez**.



Se forma una cola

El cliente 6 espera **30 segundos**. ¿Y si hubiera 3 servidores?

La solución: el balanceador de carga



Balanceador de carga

Recibe a todos los clientes en **una sola dirección** y los **reparte** entre varios servidores iguales.

El cliente

Solo conoce una dirección. No sabe cuántos servidores hay detrás.

Dónde lo verás

En Google Cloud: **Cloud Load Balancing**. También lo hace **Nginx** (Sesión 11).

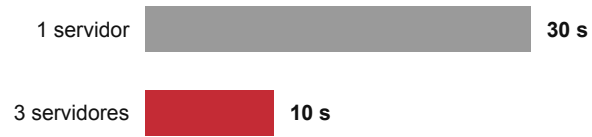
Round robin: repartir por turnos

Round robin

Un cliente para cada servidor, en orden, y se vuelve a empezar.

Cliente	Va a
1	`web-1`
2	`web-2`
3	`web-3`
4	`web-1` (otra vuelta)
5	`web-2`
6	`web-3`

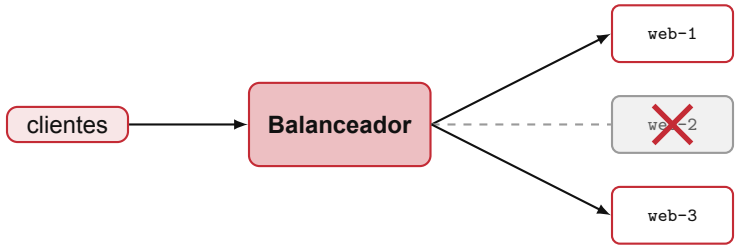
Los 6 reportes de antes



Por qué

Cada servidor hace 2 reportes, y los tres trabajan **al mismo tiempo**.

¿Y si un servidor se cae?



Verificación de estado

Cada pocos segundos, el balanceador le pregunta a cada servidor si responde. Si uno no responde, **deja de enviarle clientes** y reparte entre los que quedan.

Lo que ve el cliente

Nada raro: la página carga igual. Cuando `web-2` vuelve, el balanceador lo usa otra vez.

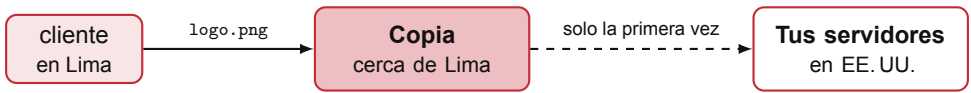
Parte 2: CDN

Copias de los archivos cerca del cliente

¿Qué es una CDN?

CDN (red de entrega de contenido)

Servidores en muchas ciudades del mundo que guardan una **copia** de tus archivos (fotos, logo) y se los entregan al cliente **desde cerca**.



La primera vez

La CDN no tiene el logo: lo pide a tus servidores, se lo entrega al cliente y **guarda una copia**.

Las siguientes veces

La CDN entrega su copia. Es más rápido y tus servidores **ni se enteran**.

¿Qué va en la CDN?

Sí va en la CDN	No va en la CDN
Logo	El carrito de Ana
Fotos de productos	Los pedidos de Luis
Archivos CSS y JavaScript	El estado de un pago

La regla

Va lo que es **igual para todos**. No va lo que **cambia según el cliente**: Luis podría recibir la copia del carrito de Ana.

En Google Cloud

Se llama **Cloud CDN** y se activa con una casilla en el balanceador de carga.

Parte 3: contenedores

El mismo programa en todos los servidores

El problema: preparar cada servidor

Para encender la tienda en `web-1`

1. Instalar Node.js, en la versión que usa la tienda.
2. Instalar las bibliotecas que usa la tienda.
3. Copiar los archivos y encender el programa.

Ahora imagina

Repetirlo en `web-2` y `web-3`. Si en uno instalas otra versión de Node.js, ese servidor podría fallar.

Contenedor (lo viste en la Sesión 12)

Un paquete con tu programa **y todo lo que necesita** para funcionar, para que corra igual en cualquier máquina.

Docker: imagen y contenedor

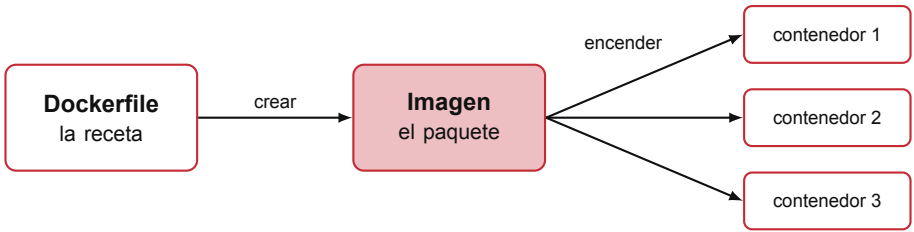


Imagen	Contenedor
El paquete guardado: el programa y todo lo que necesita. Está apagado.	Una imagen **encendida**. De una imagen puedes encender muchos contenedores iguales.

Docker es el programa que crea las imágenes y enciende los contenedores.

Cierre: preguntas para comprobar

Responde con tus palabras

1. ¿Qué hace un balanceador de carga?
2. Con 3 servidores y round robin, ¿a cuál va el cliente 4?
3. Da un ejemplo de archivo que sí va en una CDN y uno que no.
4. ¿Qué diferencia hay entre una imagen y un contenedor?
5. ¿Por qué conviene que `web-1`, `web-2` y `web-3` enciendan la misma imagen?

Idea final

Muchos clientes se atienden con varias copias iguales: el balanceador las reparte, la CDN entrega las fotos desde cerca y los contenedores hacen que todas las copias sean idénticas.

Referencias

- Google Cloud: Cloud Load Balancing y Cloud CDN: `cloud.google.com`.
- Docker: `docs.docker.com`.
- Material previo del curso: Sesión 11 (Nginx), Sesión 12 (contenedores) y Sesión 25 (supervisión y alta disponibilidad).
- Las respuestas de las preguntas están en `../respuestas.md`.